

Treinamento de um detector de queda de pessoa baseado em imagens

MC855 - Projeto em Sistemas de Programação

Visão geral

- Detector de queda de pessoa
 - segurança de idosos
 - assistência rápida
 - diminuir complicações médicas
 - auxiliar cuidadores e familiares
 - reduzir custos de saúde e internações
- Análise em tempo real de vídeo
- Convolutional neural network (CNN)
 - YOLO
- Transformação do vídeo em imagem
 - série temporal mantida pelo uso de janela
 - detecção do objeto de interesse (pessoa)
 - extração desse objeto do vídeo para composição da imagem de entrada da rede



Convolutional neural network (CNN)






Illustration of LeCun et al. 1998 from CS231n 2017 Lecture 1

Slides from Fei-Fei Li, Justin Johnson, Serena Yeung
<http://vision.stanford.edu/teaching/cs231n/>

Convolução



Do vídeo para imagem



Yolo11n

#	Module	From	n	Params	Input → Output	Arguments
0	Conv	-1	1	464	3 → 16	[3, 16, 3, 2]
1	Conv	-1	1	4,672	16 → 32	[16, 32, 3, 2]
2	C3k2	-1	1	6,640	32 → 64	[32, 64, 1, False, 0.25]
3	Conv	-1	1	36,992	64 → 64	[64, 64, 3, 2]
4	C3k2	-1	1	26,080	64 → 128	[64, 128, 1, False, 0.25]
5	Conv	-1	1	147,712	128 → 128	[128, 128, 3, 2]
6	C3k2	-1	1	87,040	128 → 128	[128, 128, 1, True]
7	Conv	-1	1	295,424	128 → 256	[128, 256, 3, 2]
8	C3k2	-1	1	346,112	256 → 256	[256, 256, 1, True]
9	C2PSA	-1	1	249,728	256 → 256	[256, 256, 1]
10	Classify	-1	1	332,802	256 → 2	[256, 2]

Treinamentos

Configurações

- Classe 0 para **não queda**
- Classe 1 para **queda**
- 200 épocas
- 4 de tamanho de batch
- Cross-Entropy Loss (função de perda)
- Stochastic Gradient Descent (SGD)
 - 0.09 de learning rate
 - 0.9 de momentum
- Yolo11n para classificação
- 6 rodadas de treinamento

Configurações

- Classe 0 para **não queda**
- Classe 1 para **queda**
- 200 épocas
- 4 de tamanho de batch
- Cross-Entropy Loss (função de perda)
- Stochastic Gradient Descent (SGD)
 - 0.09 de learning rate
 - 0.9 de momentum
- Yolo11n para classificação
- 6 rodadas de treinamento

$$\hat{y}_{i,c} = \frac{e^{z_{i,c}}}{\sum_{k=0}^1 e^{z_{i,k}}}, \quad c \in \{0, 1\}$$

$$L(w) = \frac{1}{N} \sum_{i=1}^N \ell_i = -\frac{1}{N} \sum_{i=1}^N [y_i \log \hat{y}_{i,1} + (1 - y_i) \log \hat{y}_{i,0}]$$

onde:

- $\hat{y}_{i,c}$ é a probabilidade prevista de x_i pertencer à classe c .
- $z_{i,c}$ é o logit cru (não normalizado) do modelo.

Configurações

- Classe 0 para **não queda**

- Classe 1 para **queda**

- 200 épocas

- 4 de tamanho de batch

- Cross Entropy

- Stochastic Gradient Descent (SGD)

- 0.09 de learning rate

- 0.9 de momentum

- Yolo11n para classificação

- 6 rodadas de treinamento

$$v_{t+1} = \mu v_t - \eta \cdot \nabla_w L(w_t)$$

$$w_{t+1} = w_t + v_{t+1}$$



- v_t : vetor de velocidade (direção e magnitude do movimento anterior)
- μ : coeficiente de momentum (entre 0 e 1)
- η : taxa de aprendizado
- $\nabla_w L(w_t)$: gradiente no passo atual

Treinamento 1



composição horizontal das imagens

Treinamento 1 (200 épocas e 11,6 horas de treino)



Treinamento com 5530 images. Validação com 1383 images. Imagem de 1200 x 1200



Treinamento 1 (200 épocas e 11,6 horas de treino)



Treinamento 1 (200 épocas e 11,6 horas de treino)





Treinamento 2


data augmentation de cor, brilho, contraste e recorte
composição horizontal das imagens

Treinamento 2 (186 épocas e 9,9 horas de treino)



Treinamento com 5530 images. Validação com 1383 images. Imagem de 1200 x 1200



Treinamento 2 (186 épocas e 9,9 horas de treino)



Treinamento 2 (186 épocas e 9,9 horas de treino)



Treinamento 3



composição matricial das imagens

data augmentation de cor, brilho, contraste e recorte


~~composição horizontal das imagens~~

Treinamento 3 (173 épocas e 3 horas de treino)




Treinamento com 5530 images. Validação com 1383 images. Imagem de 1200 x 1200



Treinamento 3 (173 épocas e 3 horas de treino)



Treinamento 3 (173 épocas e 3 horas de treino)



Treinamento 4

contenção de vazamento de dados (vídeos de mesma origem somente em treino ou somente em validação)






composição matricial das imagens

data augmentation de cor, brilho, contraste e recorte



~~composição horizontal das imagens~~

Treinamento 4 (200 épocas e 3,8 horas de treino)



Treinamento com 5572 images. Validação com 1386 images. Imagem de 1200 x 1200



Treinamento 4 (200 épocas e 3,8 horas de treino)



Treinamento 4 (200 épocas e 3,8 horas de treino)



Treinamento 5

data augmentation de cor, brilho, contraste, recorte e rotação
contenção de vazamento de dados (vídeos de mesma origem somente em treino ou somente em validação)



composição matricial das imagens

~~data augmentation de cor, brilho, contraste e recorte~~



~~composição horizontal das imagens~~

Treinamento 5 (200 épocas e 24,4 horas de treino)


Treinamento com 33432 images. Validação com 8316 images. Imagem de 1200 x 1200



Treinamento 5 (200 épocas e 24,4 horas de treino)



Treinamento 5 (200 épocas e 24,4 horas de treino)



Treinamento 6

validação a partir de outro dataset

data augmentation de cor, brilho, contraste, recorte e rotação

contenção de vazamento de dados (vídeos de mesma origem somente em treino ou somente em validação)



composição matricial das imagens

~~data augmentation de cor, brilho, contraste e recorte~~



~~composição horizontal das imagens~~

Treinamento 6 (106 épocas e 15 horas de treino)

Treinamento com 34790 images. Validação com 240 images. Imagem de 1200 x 1200



Treinamento 6 (106 épocas e 15 horas de treino)



Treinamento 6 (106 épocas e 15 horas de treino)







Teste qualitativo



simulação de teste de campo



ciclo completo de classificação sobre vídeo



outro *dataset*











Análise e conclusão

Análise e conclusão

- Modelo apresenta “sintomas” de *overfitting*
 - desempenho apresentando sobre os dados de treinamento não se sustenta sobre os dados de teste
 - Viés para queda
 - tende a classificar prematuramente a situação de **queda/não queda** codificada na imagem para **queda**
 - Procedimento de validação/teste são MUITO importantes
 - redes convolucionais podem sofrer *overfitting* com facilidade
 - Vazamento de dados é um problema real e acontece
- Base de dados limitada
 - apesar do conjunto de imagens de treino apresentar certa expressividade, muitos dos seus elementos são repetidos e de cenários parecidos
 - pouca variação de cenário
 - de iluminação
 - de situação de queda/não queda
 - etc
 - Qualidade da base de dados é MUITO relevante

Próximos passos

- Usar todo o *dataset* disponível para treinamento
- Coletar algumas amostras de campo e verificar o desempenho do modelo a partir de uma análise qualitativa